TALLER 2 REDES NEURONALES

SARA CANRO CAMPOS

SARA SOFIA VILLANUEVA GUARIN

KEVIN ALEJANDRO PEREZ ÑUSTES

SISTEMAS AVANZADOS DE PRODUCCIÓN

UNIVERSIDAD ECCI

FREDY ALEXANDER ORJUELA LOPEZ

ABRIL 2026

INTRODUCCIÓN

En el contexto actual de transformación digital y desarrollo de ciudades inteligentes, el análisis de datos se ha convertido en una herramienta fundamental para la toma de decisiones en sistemas productivos y logísticos. En particular, los sistemas de bicicletas compartidas representan un caso de estudio relevante, ya que integran variables operativas, temporales y ambientales que influyen directamente en la demanda del servicio. Este tipo de sistemas no solo funcionan como un medio de transporte sostenible, sino también como una fuente de información que permite optimizar recursos, mejorar la eficiencia y anticipar comportamientos del usuario.

Desde la perspectiva de la Ingeniería Industrial, predecir la demanda de bicicletas implica enfrentar problemas complejos asociados a la variabilidad del entorno, como cambios climáticos, estacionalidad y patrones de uso. Una mala estimación puede generar desequilibrios en el sistema, como exceso de inventario en ciertas estaciones o escasez en otras, afectando directamente la calidad del servicio y los costos operativos.

El presente taller tiene como objetivo aplicar técnicas avanzadas de analítica de datos, comenzando desde enfoques matemáticos como la regularización Ridge, hasta métodos de optimización numérica y modelos de aprendizaje automático como redes neuronales. A lo largo del desarrollo, se busca no solo comprender los fundamentos teóricos de estos modelos, sino también interpretar sus resultados en un contexto real, orientado a la toma de decisiones en sistemas productivos.

DESARROLLO TÉCNICO

Fase 1. Desarrollo Analítico: Regularización Ridge.

$$J(\beta) = \sum_{i=1}^{n} \left(y_i - \sum_{j=1}^{p} \beta_j x_{ij}\right)^2 + \lambda \sum_{j=1}^{p} \beta_j^2$$

$$\sum_{i=1}^{n} \left(y_i - \sum_{j=1}^{p} \beta_j x_{ij}\right)^2 = (y - X\beta)^T (y - X\beta).$$

$$\sum_{j=1}^{p} \beta_j^2 = \beta^T \beta.$$

$$J(\beta) = (y - X\beta)^T (y - X\beta) + \lambda \beta^T \beta$$

$$(y - X\beta)^T (y - X\beta) = (y^T - \beta^T X^T)(y - X\beta)$$

$$= y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X\beta$$

$$(y^T X\beta)^T = \beta^T X^T y.$$

$$(y - X\beta)^T (y - X\beta) = y^T y - 2y^T X\beta + \beta^T X^T X\beta$$

$$J(\beta) = y^T y - 2y^T X\beta + \beta^T X^T X\beta + \lambda \beta^T \beta$$

$$J(\beta) = y^T y - 2y^T X\beta + \beta^T (X^T X + \lambda I_p)\beta$$

$$\frac{\partial}{\partial \beta}(y^T y) = 0$$

$$\frac{\partial}{\partial \beta}(y^T X\beta) = X^T y$$

- Si A es simétrica, $\frac{\partial}{\partial \beta}(\beta^T A\beta) = 2A\beta.$

$$\frac{\partial J}{\partial \beta} = \frac{\partial}{\partial \beta}(y^T y) - 2\frac{\partial}{\partial \beta}(y^T X\beta) + \frac{\partial}{\partial \beta}\left[\beta^T (X^T X + \lambda I)\beta\right]$$

$$\frac{\partial}{\partial \beta}(y^T y) = 0$$

$$\frac{\partial}{\partial \beta}(y^T X\beta) = X^T y$$

$$\frac{\partial}{\partial \beta}\left[\beta^T (X^T X + \lambda I)\beta\right] = 2(X^T X + \lambda I)\beta$$

$$\frac{\partial J}{\partial \beta} = 0 - 2X^T y + 2(X^T X + \lambda I)\beta = -2X^T y + 2(X^T X + \lambda I)\beta.$$

$$-2X^T y + 2(X^T X + \lambda I)\beta = 0$$

$$-X^T y + (X^T X + \lambda I)\beta = 0$$

$$(X^T X + \lambda I)\beta = X^T y$$

$$\beta = (X^T X + \lambda I)^{-1} X^T y$$

$$\hat{\beta}_{Ridge} = (X^T X + \lambda I)^{-1} X^T y$$

Preguntas Fase 1.

Sobre la Invertibilidad: ¿Por qué la suma de λI garantiza que la matriz resultante sea invertible incluso si XT X es singular (no invertible)?

La matriz XT X puede no ser invertible cuando existe multicolinealidad, es decir, cuando algunas variables están muy relacionadas entre sí. Esto dificulta el cálculo de los coeficientes del modelo. Sin embargo, al sumar λI, se añade un valor positivo a la diagonal de la matriz, lo que corrige este problema. Como resultado, la nueva matriz XT X+λI se vuelve invertible, permitiendo obtener una solución estable y única para los coeficientes.

Efecto del Parámetro λ: ¿Qué sucede con el modelo y sus coeficientes cuando $\lambda \to 0$? ¿Y qué ocurre cuando $\lambda \to \infty$? Explique en términos de la complejidad del modelo (Sesgo vs. Varianza)

El parámetro λ controla la complejidad del modelo. Cuando λ tiende a cero, el modelo se comporta como una regresión lineal tradicional, permitiendo que los coeficientes sean grandes y ajustándose mucho a los datos. Esto produce un modelo con bajo sesgo, pero alta varianza, lo que puede generar sobreajuste.

Por el contrario, cuando λ tiende a infinito, la penalización aumenta y los coeficientes se reducen casi a cero. Esto simplifica el modelo, haciéndolo más generalizable, pero menos preciso en el ajuste. En este caso, se obtiene un modelo con alto sesgo y baja varianza, lo que puede provocar subajuste. Por lo tanto, λ permite encontrar un equilibrio entre ajustar bien los datos y evitar que el modelo sea demasiado complejo.

Fase 2: Optimización Numérica y Descenso de Gradiente

1. Impacto de la Tasa de Aprendizaje (η):

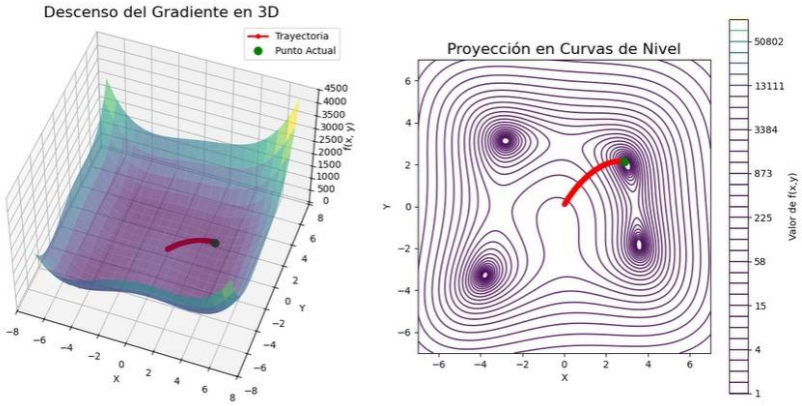

Figura [1]. Comportamiento y trayectoria del descenso del gradiente hacia el mínimo de la función con Tasa de Aprendizaje: 0.0001.

La imagen muestra el proceso de descenso del gradiente aplicado con un learning rate muy pequeño (0.0001), partiendo del punto inicial [0.0, 0.1] y ejecutando 1000 iteraciones. En la superficie tridimensional se observa cómo la trayectoria roja avanza lentamente desde la posición inicial hacia valores más bajos de la función, mientras que el punto verde marca la ubicación actual después de esas iteraciones.

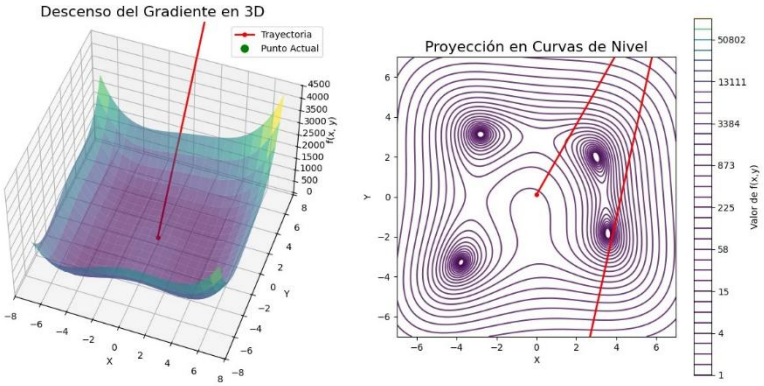

Figura [2]. Comportamiento y trayectoria del descenso del gradiente hacia el mínimo de la función con Tasa de Aprendizaje: 0.5.

- ¿Qué sucede con la trayectoria? ¿Logra llegar al centro de las curvas de nivel o comienza a oscilar/divergir?

Con un learning rate de 0.5, la trayectoria del descenso del gradiente no logra avanzar de forma estable hacia el mínimo. En lugar de converger al centro de las curvas de nivel, los pasos son tan grandes que el algoritmo comienza a oscilar y rebotar alrededor de la región óptima, e incluso puede divergir alejándose del mínimo. Esto muestra cómo una tasa de aprendizaje demasiado alta impide la convergencia y vuelve errático el proceso de optimización.

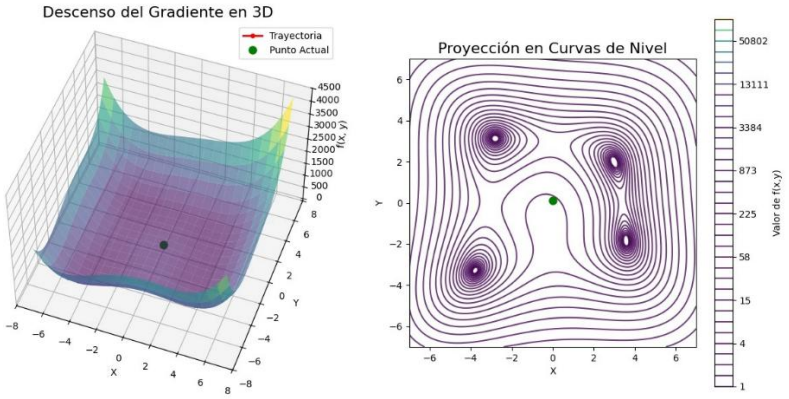

Figura [3]. Comportamiento y trayectoria del descenso del gradiente hacia el mínimo de la función con Tasa de Aprendizaje: 0.0000001.

- ¿Es suficiente este tiempo de cómputo para alcanzar el mínimo?

Con un learning rate tan pequeño (0.0000001) y solo 1000 iteraciones, el algoritmo de descenso del gradiente apenas logra moverse desde el punto inicial, ya que los pasos son demasiado diminutos para avanzar de manera significativa hacia el mínimo. El resultado es una trayectoria casi estática que permanece en la misma región, lo que evidencia que este tiempo de cómputo no es suficiente para alcanzar la solución óptima y que sería necesario

aumentar considerablemente el número de iteraciones o usar una tasa de aprendizaje mayor para lograr una convergencia efectiva.

2. Dependencia del Punto Inicial:

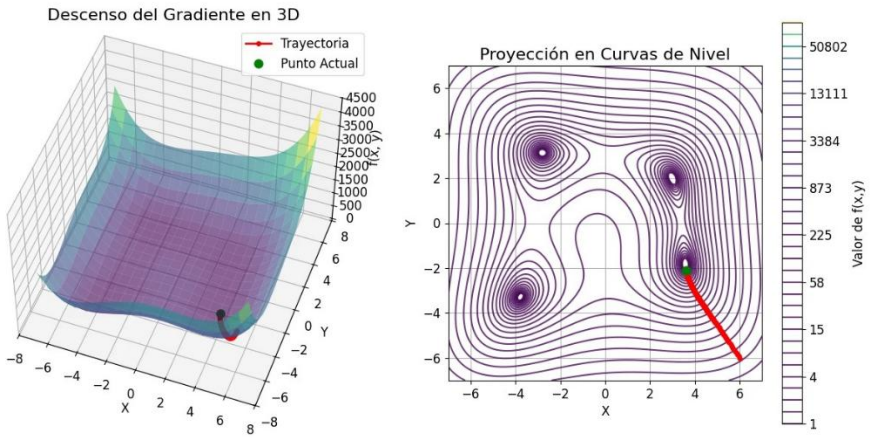

Figura [4]. Dependencia del punto inicial [-0.6, 0.6] en la convergencia del descenso del gradiente y su proyección en curvas de nivel

- ¿El algoritmo llega siempre al mismo punto final? Explique si la topografía de la función f (X, Y) sugiere la presencia de múltiples valles o mínimos locales.

Al modificar el punto inicial a coordenadas alejadas del origen, específicamente [−6.0, 6.0] y una taza de aprendizaje de 0.0001, se observa que el algoritmo de descenso del gradiente no necesariamente llega al mismo punto final. Esto ocurre porque la trayectoria del algoritmo depende directamente de la forma de la función y de la ubicación inicial desde donde comienza la optimización.

En la figura se evidencia que la función presenta una topografía compleja, caracterizada por la existencia de múltiples valles o mínimos locales, lo cual se observa claramente en las curvas de nivel, donde aparecen varias regiones cerradas que representan diferentes zonas de mínima altura (valores bajos de la función).

Debido a esta estructura, el algoritmo sigue la dirección del gradiente descendente más cercano, lo que implica que:

- Si el punto inicial está cerca de un valle específico, el algoritmo convergerá hacia ese mínimo local.
- Si se cambia el punto inicial, la trayectoria también cambia, llevando al algoritmo a otro mínimo diferente.

Por lo tanto, la función presenta múltiples mínimos locales, y esto hace que el resultado final del algoritmo dependa del punto de inicio. En consecuencia, no se garantiza que siempre se alcance el mínimo global, sino únicamente un mínimo local cercano.

Preguntas Fase 2

A partir de sus observaciones en la simulación, responda de manera crítica:

El fenómeno de "Overshooting": Explique físicamente qué ocurre cuando el paso ($\eta \cdot \nabla f$) es más grande que la distancia al mínimo. ¿Cómo se visualiza esto en el gráfico de curvas de nivel?

Cuando el paso ($\eta \cdot \nabla f$) es mayor que la distancia al mínimo, el algoritmo se pasa del punto óptimo y termina en el lado opuesto del valle. En el gráfico de curvas de nivel esto se visualiza como una trayectoria que rebota de un lado a otro del centro, sin asentarse en el mínimo, generando oscilaciones o incluso divergencia.

Eficiencia Computacional: Si el algoritmo se detiene en la iteración 1000 pero aún se encuentra lejos del mínimo, ¿qué estrategia es mejor: aumentar el número de iteraciones o ajustar la tasa de aprendizaje? Justifique su respuesta.

Si después de 1000 iteraciones el algoritmo sigue lejos del mínimo, lo más eficiente no es simplemente aumentar las iteraciones, sino ajustar la tasa de aprendizaje. Un learning rate demasiado pequeño hace que el proceso sea muy lento, mientras que uno demasiado grande provoca inestabilidad. La estrategia adecuada es encontrar un valor intermedio que permita avanzar con pasos significativos y estables, logrando convergencia en menos iteraciones.

Generalización: En un problema de ingeniería con cientos de variables (como la optimización de una cadena de suministro), ¿por qué es peligroso confiar en un ´único punto de inicio aleatorio?

En problemas de ingeniería con cientos de variables, confiar en un único punto de inicio aleatorio es riesgoso porque el algoritmo puede quedar atrapado en mínimos locales o en trayectorias poco representativas. Para evitar esto, se recomienda usar múltiples puntos iniciales, técnicas de regularización o métodos más avanzados de optimización, garantizando que la solución encontrada sea robusta y generalizable al sistema completo.

Fase 3: Redes Neuronales (MLP) y Ajuste de Hiperparámetros

Parte A: Evaluación de Métricas de Regresión

Train -> MAE: 47.086 | RMSE: 68.547 | R2: 0.858

Test -> MAE: 47.175 | RMSE: 69.458 | R2: 0.848

Preguntas Fase 3A:

Diferenciación de Métricas: Explique la diferencia técnica entre el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE). ¿Cuál de las dos penaliza con mayor severidad los errores grandes (outliers) en las ventas y por qué?

El MAE (Error Absoluto Medio) mide el promedio de los errores en valor absoluto, tratando todas las diferencias entre los valores reales y predichos de manera uniforme, mientras que el RMSE (Raíz del Error Cuadrático Medio) eleva dichos errores al cuadrado antes de promediarlos, lo que genera un mayor peso para los errores grandes. En los resultados obtenidos, el MAE es aproximadamente 47 tanto en entrenamiento como en prueba, mientras que el RMSE es más elevado (entre 68 y 69), lo cual evidencia la presencia de errores grandes en algunas predicciones. Por esta razón, se concluye que el RMSE penaliza con mayor severidad los outliers, ya que el proceso de elevación al cuadrado amplifica desproporcionadamente los errores de mayor magnitud.

Diagnóstico de Desempeño: Si el R2 en el conjunto de entrenamiento es significativamente mayor que en el de prueba, ¿qué fenómeno está ocurriendo? Proponga una solución basada en lo aprendido en la Fase 1 del taller.

Cuando se observa que el R^2 en entrenamiento (0.858) es mayor que el R^2 en prueba (0.848), se puede inferir que existe un leve sobreajuste (overfitting), ya que el modelo presenta un mejor desempeño con los datos con los que fue entrenado que con datos nuevos. Aunque la diferencia no es muy grande, sí indica que el modelo comienza a ajustarse no solo a los patrones reales, sino también a ciertas variaciones específicas de los datos de entrenamiento, conocidas como ruido, que corresponden a comportamientos aleatorios o situaciones particulares que no se repiten en nuevos datos.

Para mitigar este problema, se puede aplicar lo trabajado en la Fase 1, donde se implementó la regularización Ridge, incorporando un término de penalización que reduce la magnitud de los coeficientes. De esta manera, se controla la complejidad del modelo y se evita que este se ajuste a ese ruido, permitiendo que capture únicamente las relaciones más relevantes y mejorando así su capacidad de generalización.

Interpretación de Residuos: Al observar la gráfica de y_real vs y_pred, ¿se identifica algún patrón de error sistemático?

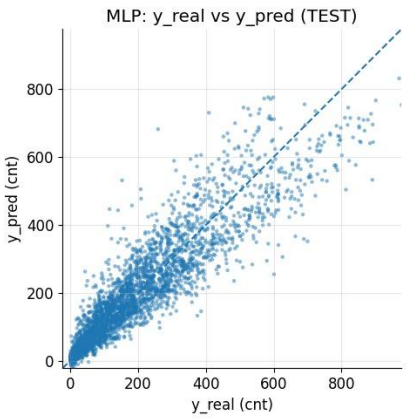

Figura [5]. Desempeño del modelo MLP: relación entre valores reales y predicciones (TEST).

Al observar la gráfica de y_real vs y_pred, se identifica un patrón de error sistemático en el modelo. En particular, para valores altos de y_real, muchos puntos se ubican por debajo de la línea diagonal (línea de predicción perfecta), lo que indica que el modelo tiende a subestimar las ventas altas. Por otro lado, en valores bajos, las predicciones se ajustan mejor y muestran menor dispersión. Además, se observa que la variabilidad del error aumenta a medida que crecen los valores reales, lo que sugiere que el modelo tiene más dificultad para predecir correctamente en rangos altos de demanda. En conclusión, el modelo presenta un sesgo hacia la subestimación en valores altos y un aumento del error en esos rangos.

Parte B: Optimización con GridSearchCV

MLP (MEJOR MODELO)

Train -> MAE: 46.816 | RMSE: 68.336 | R2: 0.859

Test -> MAE: 46.512 | RMSE: 68.550 | R2: 0.852

1. Arquitectura (hidden layer sizes): Compare una red “profunda” (más capas, ej. (32,16,8,4)) contra una “ancha” (una sola capa con muchas neuronas, ej. (64,)).

La arquitectura de la red (hidden_layer_sizes) determina su profundidad y ancho, lo que influye directamente en su capacidad de aprendizaje. Una red profunda, como (32,16,8,4), tiene varias capas que le permiten capturar relaciones más complejas y no lineales mediante representaciones más abstractas, aunque con mayor riesgo de sobreajuste. En cambio, una red ancha, como (64,), concentra muchas neuronas en una sola capa, siendo más simple de entrenar, pero con menor capacidad para modelar patrones complejos. En general, aumentar capas y neuronas mejora la

capacidad del modelo, pero también incrementa el riesgo de sobreajuste, por lo que es necesario encontrar un equilibrio adecuado.

2. Regularización (Alpha): Conecte esto con la Fase 1. Pruebe valores como [1e-5, 1e-2, 1.0]. ¿Cómo afecta un α muy elevado a la capacidad de aprendizaje?

La regularización (alpha) en el modelo MLP cumple un papel similar al parámetro λ en la regresión Ridge vista en la Fase 1, ya que ambos penalizan la magnitud de los coeficientes para controlar la complejidad del modelo. En los resultados obtenidos, el mejor valor encontrado fue $\alpha = 0.001$, lo que indica que una regularización moderada permite al modelo aprender adecuadamente sin volverse demasiado complejo. Esto se refleja en un buen desempeño tanto en entrenamiento ($R^2 = 0.859$) como en prueba ($R^2 = 0.852$), evidenciando una buena capacidad de generalización.

Cuando el valor de α es muy elevado (por ejemplo, cercano a 1.0), la penalización sobre los pesos se vuelve demasiado fuerte, forzando a que estos se reduzcan excesivamente. Como consecuencia, el modelo pierde capacidad de aprendizaje, ya que no logra capturar relaciones importantes entre las variables, generando un modelo demasiado simple. Esto produce un alto sesgo (underfitting), donde tanto el desempeño en entrenamiento como en prueba disminuyen, afectando la precisión de las predicciones.

3. **Tasa de Aprendizaje (learning rate init):** Conecte esto con la Fase 2. Analice cómo influye en el número de iteraciones necesarias para que el Early Stopping se active.

   La tasa de aprendizaje (learning_rate_init) está directamente relacionada con lo analizado en la Fase 2, ya que controla el tamaño de los pasos que da el algoritmo durante el descenso de gradiente. Un valor alto permite avanzar más rápido hacia el mínimo, por lo que el

modelo puede converger en menos iteraciones y activar el Early Stopping rápidamente; sin embargo, también puede generar oscilaciones o inestabilidad. Por otro lado, un valor muy bajo hace que el aprendizaje sea más lento, aumentando el número de iteraciones necesarias para mejorar el error, lo que puede retrasar la activación del Early Stopping o incluso impedir que el modelo alca

Preguntas Fase 3B:

Consistencia de Parámetros: Compare el valor óptimo de alpha encontrado por el GridSearch con lo que analizó en la sección de Regresión Ridge. ¿Existe una relación entre la complejidad de la red y la necesidad de regularización?

El valor óptimo de $\alpha = 0.001$ encontrado mediante Grid Search es coherente con lo observado en la regresión Ridge de la Fase 1, donde una regularización moderada permitió controlar la complejidad del modelo sin afectar su capacidad de aprendizaje. Esto evidencia que no se requiere una penalización alta, sino un equilibrio adecuado. Además, existe una relación directa entre la complejidad de la red y la necesidad de regularización: a mayor número de capas o neuronas, mayor es el riesgo de sobreajuste y, por tanto, mayor la necesidad de regularizar; en este caso, como la arquitectura (16, 8, 4) es de complejidad moderada, un valor bajo de α fue suficiente para lograr buen desempeño y generalización.

Early Stopping: Explique cómo este mecanismo ayuda a optimizar el tiempo de cómputo y a prevenir el sobreajuste basado en sus resultados.

El mecanismo de Early Stopping ayuda a optimizar el tiempo de cómputo porque detiene automáticamente el entrenamiento cuando el modelo deja de mejorar en el conjunto de validación,

evitando iteraciones innecesarias que no aportan mejoras en el desempeño. En los resultados obtenidos, donde el modelo presenta métricas muy similares entre entrenamiento ($R^2 = 0.859$) y prueba ($R^2 = 0.852$), se evidencia que el entrenamiento se detuvo en un punto adecuado, logrando un buen equilibrio. Además, este mecanismo previene el sobreajuste, ya que evita que el modelo continúe aprendiendo patrones específicos o ruido del conjunto de entrenamiento, permitiendo que mantenga una buena capacidad de generalización hacia datos nuevos.

Conclusión de Negocio: Basándose en el mejor modelo encontrado, ¿cuál es el margen de error promedio que la empresa debería esperar al predecir sus ventas? ¿Es el modelo lo suficientemente robusto para decisiones presupuestales? Justifique.

Basándose en el mejor modelo encontrado, la empresa debería esperar un margen de error promedio cercano a 46 unidades en sus predicciones de ventas, de acuerdo con el MAE en el conjunto de prueba (46.512), mientras que el RMSE (~68.55) indica que errores más grandes también pueden ocurrir, aunque con menor frecuencia. Además, el valor de $R^2 = 0.852$ muestra que el modelo explica una alta proporción de la variabilidad de las ventas, y la cercanía con el resultado en entrenamiento ($R^2 = 0.859$) evidencia una buena capacidad de generalización. En conjunto, estos resultados sugieren que el modelo es lo suficientemente robusto para apoyar decisiones presupuestales, aunque se debe considerar el margen de error en la planeación, especialmente en escenarios donde pequeñas desviaciones puedan tener un impacto significativo.

Fase 4: Propagación hacia Adelante (Forward Propagation) Manual

$X = [0{,}5, 0{,}3, 0{,}2]^T$

$$Z_1 = W_{11}X_1 + W_{12}X_2 + W_{13}X_3 + b_1^{[1]}$$

$$Z_1 = 0{,}2\ x\ 0{,}5 + 0{,}5\ x\ 0{,}3 + (-0{,}1)\ x\ 0{,}2 + 0{,}1 = 0{,}33$$

$$Z_2 = 0{,}8\ x\ 0{,}5 + (-0{,}3) x\ 0{,}3 + 0{,}4\ x\ 0{,}2 + (-0{,}2) = 0{,}19$$

$$Z_3 = (-0{,}5) x\ 0{,}5 + 0{,}1\ x\ 0{,}3 + 0{,}2\ x\ 0{,}2 + 0{,}0 = -0{,}18$$

Figura [6]. Puntaje de la Capa Oculta.

$$\frac{1}{1 + e^{-Z_1}}$$

$$W^{(1)} = \begin{pmatrix} 0{,}2 & 0{,}5 & -0{,}1 \\ 0{,}8 & -0{,}3 & 0{,}4 \\ -0{,}5 & 0{,}1 & 0{,}2 \end{pmatrix}, \quad b^{(1)} = \begin{pmatrix} 0{,}1 \\ -0{,}2 \\ 0{,}0 \end{pmatrix}$$

	$W^{(1)}$		
0,2	0,5	-0,1	0,5
0,8	-0,3	0,4	0,3
-0,5	0,1	0,2	0,2

0,23	0,1	Z1	0,33
0,39	-0,2	Z2	0,19
-0,18	0	Z3	-0,18

Figura [7]. Activación de la Capa Oculta

SIGMOIDE	
0,58175938	ENTRA A LA CAPA 2
0,54735762	
0,45512111	

$$W^{(2)} = \begin{pmatrix} 0{,}5 & -0{,}4 & 0{,}1 \\ 0{,}2 & 0{,}8 & -0{,}5 \\ -0{,}1 & 0{,}3 & 0{,}7 \end{pmatrix}, \quad b^{(2)} = \begin{pmatrix} -0{,}1 \\ 0{,}2 \\ 0{,}1 \end{pmatrix}$$

	$W^{(1)}$		
0,5	-0,4	0,1	0,58175938
0,2	0,8	-0,5	0,54735762
-0,1	0,3	0,7	0,45512111

0,11744875	-0,1	SALIDA 1	0,01744875
0,32667742	0,2	SALIDA 2	0,52667742
0,42461612	0,1	SALIDA 3	0,52461612

Figura [8]. Puntaje de la Capa de Salida.

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^{3} e^{z_j}}$$

$$\frac{e^{salida\ 1}}{e^{salida\ 1} + e^{salida\ 2} + e^{salida\ 3}} \qquad \frac{e^{salida\ 2}}{e^{salida\ 1} + e^{salida\ 2} + e^{salida\ 3}} \qquad \frac{e^{salida\ 3}}{e^{salida\ 1} + e^{salida\ 2} + e^{salida\ 3}}$$

SOFTMAX		
0,23123591	23,1235905	CLASE 1
0,38477821	38,4778209	CLASE 2
0,38398589	38,3985886	CLASE 3
1		

Figura [9]. Probabilidades de Clase.

Preguntas Fase 4:

Interpretación de Resultados: Según las probabilidades obtenidas, ¿en qué categoría clasifica la red a esta campaña publicitaria?

Según las probabilidades obtenidas mediante la función Softmax, la clase con mayor valor es **C2 (Impacto Medio)** con una probabilidad aproximada del 38.5%.

Esto indica que según los patrones aprendidos por la red neuronal la combinación de inversión en TV, radio y prensa genera un impacto que no es ni bajo ni altamente dominante, sino intermedio. Es importante resaltar que la diferencia entre C2 y C3 es mínima, lo que sugiere que la red percibe cierta ambigüedad en la clasificación, es decir, la campaña tiene características cercanas tanto a impacto medio como alto.

Esto indica que la red neuronal clasifica la campaña publicitaria como de impacto medio, ya que esta categoría presenta la mayor probabilidad frente a las demás. Aunque la clase C3 tiene un valor muy cercano, no supera a C2, por lo que la decisión final del modelo se basa en el criterio de máxima probabilidad.

Función de Activación: ¿Por qué utilizamos Softmax en la última capa en lugar de una función lineal o una sigmoide simple? Explique en términos de la suma de las probabilidades.

La función Softmax se utiliza en la capa de salida porque permite transformar los valores lineales obtenidos en una distribución de probabilidades, donde cada valor está entre 0 y 1 y la suma total es igual a 1.

Esto es fundamental en problemas de clasificación multiclase, ya que no solo se busca determinar la clase más probable, sino también cuantificar el nivel de confianza del modelo en cada posible categoría. Esta propiedad, Softmax facilita la interpretación de los resultados y permite comparar directamente las probabilidades entre clases.

A diferencia de otras funciones:

- **Función lineal:** No restringe los valores, por lo que no permite interpretarlos como probabilidades.
- **Función sigmoide:** Aunque produce valores entre 0 y 1, trata cada salida de forma independiente, lo cual es adecuado para clasificación binaria, pero no garantiza que las probabilidades sumen 1 en problemas multiclase.

Softmax, en cambio, introduce una normalización exponencial que resalta las diferencias entre los valores de entrada, haciendo que la clase con mayor activación tenga una probabilidad dominante, sin perder la relación con las demás clases.

Rol del Bias: ¿Qué sucedería con la capacidad de representación de la red si todos los vectores de sesgo (b) fueran cero?

El Bias (sesgo) permite ajustar el punto de activación de cada neurona, funcionando como un término independiente que desplaza la función de activación.

Si todos los valores de bias fueran cero:

- La red perdería flexibilidad para ajustarse a los datos.
- Las neuronas dependerían únicamente de las entradas.
- Se limitaría la capacidad del modelo para representar relaciones complejas.
- Podría generar un peor desempeño en la clasificación.

En conclusión, el Bias es fundamental porque mejora la capacidad de aprendizaje y representación de la red neuronal.

Fase 5: Evaluación de Modelos y Toma de Decisiones (Caso: Mantenimiento Predictivo)

El Desafío del Desbalance de Clases

Preguntas Fase 5A:

Análisis de Pesos: Si el modelo indica que los errores en la Clase 1 (Fallo) pesarán aproximadamente 14.7 veces más que en la Clase 0, ¿qué intenta corregir el algoritmo al configurar el parámetro class weight durante el entrenamiento?

El uso del parámetro class_weight en el entrenamiento del modelo busca corregir el problema de desbalance de clases en los datos. En este caso, la Clase 1 (Fallo) aparece con mucha menor frecuencia que la Clase 0, por lo que el modelo podría aprender a ignorarla y predecir mayormente la clase dominante. Al asignar un peso aproximadamente 14.7 veces mayor a la Clase 1, el algoritmo penaliza más los errores cometidos en esta clase, obligando al modelo a prestarle mayor atención durante el entrenamiento. De esta manera, se mejora la capacidad del modelo para detectar fallos, evitando que se sesgue hacia la clase mayoritaria y logrando un aprendizaje más equilibrado.

La Trampa de la Exactitud: Explique por qué en este caso un Accuracy del 95 % podría considerarse un resultado deficiente para la gestión de mantenimiento si el modelo no logra detectar los fallos reales.

Un valor alto de accuracy (exactitud), como 95%, puede ser engañoso en problemas de mantenimiento predictivo cuando existe desbalance de clases. En este caso, la mayoría de los datos corresponden a condiciones normales (Clase 0), mientras que los fallos (Clase 1) son poco frecuentes. Por ello, un modelo podría predecir casi siempre “no fallo” y aun así obtener una alta exactitud, sin realmente cumplir su objetivo principal.

El problema es que el modelo podría estar fallando en detectar los casos más importantes: los fallos reales. En un contexto de mantenimiento, no identificar un fallo puede generar costos elevados, paradas no programadas o incluso riesgos operativos. Por lo que, un accuracy alto no garantiza un buen desempeño si el modelo no logra identificar correctamente los eventos críticos.

Interpretación de la Matriz de Confusión

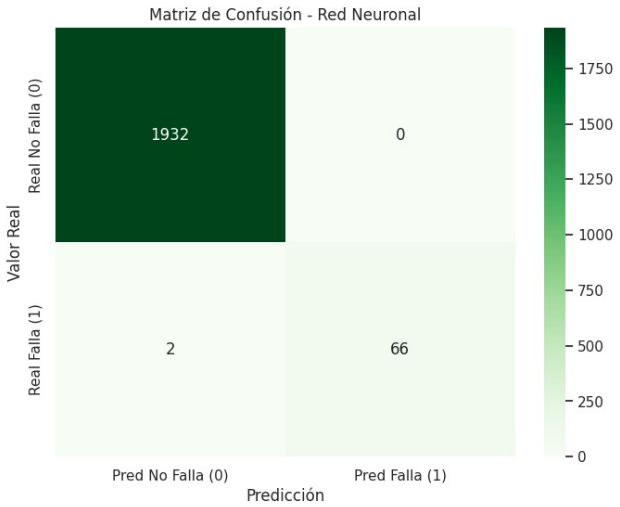

Figura [10]. Matriz de confusión del modelo de red neuronal para la detección de fallos.

1. **Precision (Precisión):** T P / T P +F P — ¿Qué tan confiable es el modelo cuando emite una alerta de falla?

TP= 66

FP= 0

$$Precisión = \frac{66}{66 + 0} = 1{,}0$$

Esto significa que el modelo tiene una precisión del 100%, es decir, cada vez que el modelo predice un fallo, siempre acierta. No genera falsas alarmas, lo cual es muy positivo en términos operativos.

2. **Recall (Sensibilidad):** T P/ T P +F N — ¿Qué porcentaje de los fallos reales totales logró capturar el modelo?

TP= 66

FN=2

$$Recall = \frac{66}{66+2} = 0{,}9706$$

Esto indica que el modelo detecta aproximadamente el 97.06% de los fallos reales, lo cual es un desempeño muy alto, aunque aún existen algunos fallos que no se detectan

3. Costo Total de Error: Calcule el impacto económico mensual del modelo utilizando la fórmula:

Costo = (F N × 5000) + (F P × 200)

FN=2

FP=0

$$\text{Costo} = (2 \times 5000) + (0 \times 200) = 10000 \text{ USD}$$

El costo total es de USD 10,000, debido a los fallos que no fueron detectados. Aunque no hay falsas alarmas, los errores de tipo FN son muy costosos, lo que resalta la importancia de maximizar el recall en este tipo de problemas.

Preguntas de Reflexión y Negocio Fase 5

Trade-off entre Recall y Precision: En el contexto de evitar paradas de línea críticas, ¿preferiría usted un modelo con un Recall del 98 % pero una Precision del 60 %, o viceversa? Justifique su respuesta basándose en los costos calculados anteriormente.

En el contexto de evitar paradas de línea críticas, sería preferible un modelo con Recall del 98 % y Precision del 60 %. La razón principal es que, en mantenimiento predictivo, el error más costoso es no detectar un fallo real, es decir, los falsos negativos. Según el caso planteado, cada fallo no detectado cuesta USD 5,000, mientras que una falsa alarma solo cuesta USD 200. Por eso, desde el punto de vista económico y operativo, conviene priorizar un modelo que capture la mayor cantidad posible de fallos reales.

Aunque una precisión del 60 % implica que habrá más falsas alarmas, estas tienen un costo mucho menor y pueden manejarse mediante inspecciones preventivas. En cambio, si se eligiera el caso contrario, con alta precisión, pero bajo recall, el modelo emitiría menos alertas incorrectas, pero dejaría pasar más fallos reales, lo cual generaría mayores pérdidas económicas y riesgos para la continuidad de la producción.

Curva de Aprendizaje: Observe la gráfica de loss (pérdida) y accuracy durante el entrenamiento. ¿Considera que 30 épocas son suficientes para que el modelo converja? ¿Qué sucede con el error de validación comparado con el de entrenamiento?

Al observar la evolución de las métricas durante el entrenamiento, se puede concluir que 30 épocas son más que suficientes para que el modelo converja. Esto se debe a que, desde aproximadamente la época 8–10, tanto el accuracy como el recall en validación alcanzan valores cercanos a 1.0 y se mantienen estables, mientras que la pérdida (loss) de validación deja de disminuir significativamente. Esto indica que el modelo ya aprendió los patrones principales de los datos y continuar entrenando no aporta mejoras relevantes.

En cuanto al comportamiento del error, se observa que la pérdida de validación es incluso menor o muy similar a la de entrenamiento durante casi todo el proceso, lo cual es una señal positiva.

Esto sugiere que el modelo no está sobreajustando (overfitting), sino que generaliza bien a datos no vistos. Además, la estabilidad de las métricas en validación confirma que el modelo ha alcanzado un punto de convergencia adecuado.

De este modo, el modelo converge antes de las 30 épocas y presenta un buen equilibrio entre entrenamiento y validación, sin evidencia clara de sobreajuste.

Conclusión Final del Taller: Tras recorrer desde la regresión analítica hasta la clasificación con redes neuronales, ¿cómo puede el uso de métricas avanzadas (como el Recall) transformar la rentabilidad de una empresa de manufactura?

El uso de métricas avanzadas como el Recall puede transformar significativamente la rentabilidad de una empresa de manufactura, ya que permite enfocarse en detectar correctamente los casos críticos, como fallos o defectos en producción. A diferencia de métricas generales como la accuracy, el Recall mide qué tan bien el modelo identifica los casos positivos, por ejemplo, productos defectuosos, lo cual es clave cuando estos son poco frecuentes pero costosos. Un alto Recall, como el observado en los resultados cercano a 1.0, asegura que casi ningún fallo pase desapercibido, reduciendo costos asociados a devoluciones, reprocesos o daños en la reputación. De esta manera, el modelo no solo mejora el desempeño técnico, sino que impacta directamente en la eficiencia operativa y en la toma de decisiones, aumentando la rentabilidad al minimizar riesgos y pérdidas.

Conclusiones

El desarrollo del taller permitió comprender la integración entre fundamentos matemáticos, optimización numérica y modelos de aprendizaje automático para la solución de problemas complejos en ingeniería. La regularización Ridge evidenció la importancia de controlar la complejidad del modelo y el equilibrio entre sesgo y varianza para mejorar la generalización.

Asimismo, el análisis del descenso de gradiente destacó la sensibilidad del proceso de optimización frente a la tasa de aprendizaje y el punto inicial, factores clave para garantizar la convergencia y eficiencia computacional. En cuanto a las redes neuronales, la optimización de hiperparámetros permitió obtener un modelo con buen desempeño y capacidad de generalización, validando la relación entre arquitectura, regularización y rendimiento.

El cálculo manual de la propagación hacia adelante facilitó la comprensión del funcionamiento interno de la red neuronal, especialmente en la transformación de entradas en probabilidades mediante funciones de activación. Finalmente, el uso de métricas como el Recall en el contexto de mantenimiento predictivo demostró que la evaluación del modelo debe alinearse con el impacto económico, priorizando la detección de eventos críticos sobre métricas generales como la exactitud.

En conjunto, se concluye que la correcta selección, ajuste e interpretación de los modelos analíticos es fundamental para apoyar la toma de decisiones y mejorar la eficiencia en sistemas productivos.

Referencias

Orjuela López, F. A. (2026). *Semana 8-9 — Clasificación y evaluación de modelos* [Notebook de Google Colab]. GitHub.

https://colab.research.google.com/github/faorjuelal/SAPP---IIND---2026/blob/main/Notebooks/Semana8_9.ipynb

Orjuela López, F. A. (2026). CalculoRed.

https://www.youtube.com/watch?v=vANCP2iVoW8